

Modelado y validación de supuestos de regresión en R

Desempeño académico y porcentaje de comidas gratuitas

Monsalvo Velázquez Naomi Adai

Contents

Preparación e importación	1
i. Ajuste del modelo inicial y verificación de supuestos	1
Interpretación original del modelo inicial	3
ii. Transformación de variables y segundo modelo	3
Interpretación de la transformación	3
Interpretación del segundo modelo	4
iii. Comparación de los modelos	5
Interpretación original de la comparación	5
iv. Coeficiente de determinación y ANOVA	5
Interpretación original de los resultados	7
v. Prueba de hipótesis con el modelo final	7
Interpretación original de la prueba	8

Este documento organiza el ejercicio académico original en secciones de análisis. Las interpretaciones están transcritas del trabajo original.

Preparación e importación

```
rm(list = ls(all.names = TRUE))
gc()

#Primero vamos a cargar las librerias
library(ggplot2)
library(lmtest)
library(car)
library(multcomp)

# Cargamos la base de datos
Datos <- read.csv("C:/Users/naomi/OneDrive/Documents/ModelosNP/performance.csv", header = TRUE)
```

i. Ajuste del modelo inicial y verificación de supuestos

- i. Ajustar un modelo de regresión lineal simple. Verificar los supuestos a partir de este modelo. Deberá indicar para cada supuesto qué gráfica o prueba sirve para argumentar el cumplimiento o no del supuesto

```
#Modelo 1. observamos sin modificar las variables de nuestra base datos
```

```
Ajuste1 <- lm(api00 ~ meals, data = Datos)
```

```
# Primero veremos como se ven los supuestos de linealidad, homocedasticidad y normalidad de nuestros datos
```

```
# X11() # No se ejecuta al tejer R Markdown
```

```
par(mfrow=c(1,3), mar=c(4, 4, 4, 1))
```

```
plot(Ajuste1, 1, main=" Linealidad", sub.caption="")
```

```
plot(Ajuste1, 3, main=" Homocedasticidad", sub.caption="")
```

```
plot(Ajuste1, 2, main=" Normalidad", sub.caption="")
```




Figure 1: Diagnósticos del modelo inicial

```
# Aplicaremos las pruebas linealidad y homocedasticidad
```

```
lmtest::bptest(Ajuste1)
```

```
studentized Breusch-Pagan test
```

```
data: Ajuste1
```

```
BP = 9.6387, df = 1, p-value = 0.001905
```

```
car::ncvTest(Ajuste1)
```

```
Non-constant Variance Score Test
```

```
Variance formula: ~ fitted.values
```

```
Chisquare = 9.832368, Df = 1, p = 0.0017147
```

```
# Para boxTidwell, sumamos una constante (+1) a 'meals'
```

```
# dado que sabemos que la prueba no acepta valores de cero, es por esto que sumamos esta constante
```

```
Datos$meals_pos <- Datos$meals + 1
```

```
car::boxTidwell(api00 ~ meals_pos, data = Datos)
```

```
MLE of lambda Score Statistic (t) Pr(>|t|)
1.2132 -2.236 0.02591 *
```

```
---
```

```
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
iterations = 3
```

Interpretación original del modelo inicial

- Gráfica Residuals vs Fitted, es decir Linealidad, mientras que en la gráfica podemos observar que el comportamiento forma una línea curvada lo que nos indica no es lineal, sin embargo usamos Box-Tidwell para confirmarlo y para esto usa de hipótesis H_0 : Es lineal (el parámetro $\lambda = 1$) H_1 : NO es lineal (λ distinto de 1). En este caso el valor de p-value de $p=0.025$, así dado por esto y debido a que $p < 0.05$ notamos que el supuesto de linealidad NO se cumple.
- Gráfica - Scale-Location, es decir homocedasticidad, observamos que la línea no es horizontal completamente y los puntos se ven bastante dispersos, sin embargo usamos las pruebas bptest que nos dio un valor de p-value de $p=0.0019$ y la prueba ncvtTest cuyo resultado fue $p=0.0017$, recordando que las dos pruebas tomas como hipótesis H_0 : Varianza constante vs H_1 : Varianza no constante Y que el valor obtenido de ambas pruebas fueron menores de 0.05, es decir $p < 0.05$, entonces rechazamos H_0 es decir, concluimos que el supuesto de homocedasticidad NO se cumple.
- Gráfica Q-Q residuals, es decir normalidad, en nuestra gráfica vemos que los puntos en el centro de la línea caen sobre ella, pero en los extremos algunos puntos se alejan

ii. Transformación de variables y segundo modelo

- a. Para transformar la variable $Y =$ academic performance of the school (api00) usaremos BoxCox para observar que valor de λ que sugiere transformar a nuestra variable Y

```
summary(car::powerTransform(Ajuste1))
```

```
bcPower Transformation to Normality
  Est Power Rounded Pwr Wald Lwr Bnd Wald Up Bnd
Y1      1.5883      1.59      1.2631      1.9134
```

```
Likelihood ratio test that transformation parameter is equal to 0
(log transformation)
```

```
              LRT df          pval
LR test, lambda = (0) 85.6489  1 < 2.22e-16
```

```
Likelihood ratio test that no transformation is needed
```

```
              LRT df          pval
LR test, lambda = (1) 12.38521  1 0.00043275
```

Interpretación de la transformación

Observamos que en nuestra salida, el valor de λ obtenido es de 1.5883 Sin embargo, recordando que usualmente el valor de la transformación que normalmente usamos es elevar al cuadrado, entonces primero intentaremos aplicar esta transformación

```
# Transformamos la variable Y, de acuerdo a lo que obtuvimos de la salida anterior
Datos$api00_cuad <- Datos$api00^2
```

```
# Realizamos un ajuste al Modelo II tomando la transformación de la variable Y que ya vimos
Ajuste2 <- lm(api00_cuad ~ meals, data = Datos)
```

```
# Volvimos a generar las graficas de los supuestos de linealidad, homocedasticidad y normalidad
# X11() # No se ejecuta al tejer R Markdown
par(mfrow=c(1,3), mar=c(4, 4, 4, 1))
plot(Ajuste2, 1, main="Linealidad (modelo 2)", sub.caption="")
plot(Ajuste2, 3, main="Homocedasticidad (modelo 2)", sub.caption="")
plot(Ajuste2, 2, main="Normalidad (modelo 2)", sub.caption="")
```




Figure 2: Diagnósticos del modelo transformado

```
lmtest::bptest(Ajuste2)
```

studentized Breusch-Pagan test

```
data: Ajuste2
BP = 0.65377, df = 1, p-value = 0.4188
```

```
shapiro.test(resid(Ajuste2))
```

Shapiro-Wilk normality test

```
data: resid(Ajuste2)
W = 0.99589, p-value = 0.3838
```

Interpretación del segundo modelo

Ajustamos el modelo 2 y obtenemos $E(y^2; x) = \beta_0 + \beta_1 * x$, donde $y = \text{api00}$, $x = \text{meals}$. Es decir: $E[\text{api00}^2; \text{meals}] = b_0 + b_1 * \text{meals}$. Transformamos la variable Y al elevarla al cuadrado, esto debido a nuestra prueba BoxCox. Pero para verificarlo observamos el cambio que presentan las gráficas de nuestros supuestos, pero con nuestra variable Y transformada. Y vemos que:

- Gráfica Residuals vs Fitted donde nuestro supuesto de linealidad: $E(y_i; x_i) = \beta_0 + \beta_1 * x_i$: Mientras que en el modelo anterior se veía una curva, en esta nueva gráfica vemos que la línea es muchísimo más recta, cercana a ser completamente horizontal, es por esto que podríamos concluir que se cumple la linealidad
- Gráfica Scale-Location donde nuestro supuesto de homocedasticidad: $\text{Var}(\epsilon_i) = \sigma^2$: Observamos que los puntos se ven dispersos y la línea central tiene una curva menos prominente que la del modelo 1. Sin embargo para confirmar si se cumple el supuesto usamos bptest que toma las hipótesis: H_0 : La varianza es constante H_1 : La varianza NO es constante. Al correr la prueba nos dio un p-value = 0.4188 y dado que $p > 0.05$, entonces NO rechazamos H_0 . Es por esto que concluimos que hay evidencia estadística suficiente para decir que el supuesto de homocedasticidad no se cumple
- Gráfica Q-Q residuals, el supuesto de normalidad. En la gráfica notamos que visualmente no hay gran cambio, es decir los valores continúan estando bastante cerca que en la gráfica anterior, sin embargo para estar seguros que se cumple normalidad aplicamos shapiro-test cuyas hipótesis que toma son: H_0 : Los

errores provienen de la distribución Normal H1: Los errores NO provienen de la distribución Normal lo que nos dio como resultado un p-value = 0.3838, y como $p > 0.05$, NO rechazamos H_0 . Por lo que concluimos que se cumple la normalidad en este modelo. Así al modificar nuestra base transformando la variable Y (elevándola al cuadrado) notamos que da como resultado que los supuestos de linealidad, homocedasticidad y normalidad se cumplan. Es por esto que no hicimos un cambio a la variable X (meals).

iii. Comparación de los modelos

```
# X11()
par(mfrow=c(1,1), mar=c(5, 4, 4, 2))
plot(Datos$meals, Datos$api00, xlab="Meals", ylab="API00", pch=19, col="green",
     main="Comparación de Modelos 1 y 2")

# Recta de regresión del Modelo 1
abline(Ajuste1, col="red", lwd=2)

# Curva del Modelo II regresada a la escala original (Verde)
# Como elevamos al cuadrado, la operación inversa es la RAÍZ CUADRADA
curva <- function(x){ sqrt(Ajuste2$coefficients[1] + Ajuste2$coefficients[2]*x) }
curve(curva, add = TRUE, col="blue", lwd=3)

legend("topright", legend=c("Modelo 1", "Modelo 2"),
      col=c("red", "blue"), lty=1, lwd=2)
```

Interpretación original de la comparación

Creemos una gráfica que presente ambos modelos y los puntos originales de la base de datos. Sin embargo, dado que el ejercicio pide la gráfica en escala original, notamos que nosotros modificamos la variable Y, elevándola al cuadrado de esta forma: $E(y^2; x) = \beta_0 + \beta_1 * x$, es por esto que vamos a despejar la variable Y sola, por lo que aplicamos raíz cuadrada para dejar solo la variable Y: $y = \sqrt{\beta_0 + \beta_1 * x}$ y así obtenemos la gráfica del modelo 2 colocado en la escala original, es decir con y = academic performance of the school (api00) y x = percentage of students receiving free meals (meals).

iv. Coeficiente de determinación y ANOVA

```
summary(Ajuste2) # Usamos summary para obtener el coeficiente de determinacion de R^2
```

Call:

```
lm(formula = api00_cuad ~ meals, data = Datos)
```

Residuals:

Min	1Q	Median	3Q	Max
-215856	-53541	-6255	53381	237653

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	761544.5	8301.9	91.73	<2e-16 ***
meals	-5337.7	121.7	-43.86	<2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 77570 on 398 degrees of freedom




Figure 3: Comparación de los modelos en escala original

Multiple R-squared: 0.8286, Adjusted R-squared: 0.8282
 F-statistic: 1924 on 1 and 398 DF, p-value: < 2.2e-16

```
anova(Ajuste2) # Aplicamos la prueba ANOVA
```

Analysis of Variance Table

Response: api00_cuad

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
meals	1	1.1577e+13	1.1577e+13	1923.8	< 2.2e-16 ***
Residuals	398	2.3950e+12	6.0176e+09		

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Interpretación original de los resultados

-Para el modelo 2 obtuvimos que el coeficiente de determinación fue R-squared: 0.8286, sabemos que este coeficiente nos ayuda a medir la eficacia de ajuste en los datos de la base, así entonces como obtuvimos R-squared sabemos que aprox el 82.86% de la variabilidad de Y en escala cuadrática se explica dado el porcentaje de la otra variable (X), así podemos saber que el 17.14% restante es la variación de valores que no se consideraron

Por otro lado hicimos el ANOVA test, dicho test nos permite revisar el nivel de significancia del modelo, tomando las siguientes hipótesis: H0: $\beta_1 = 0$ ($\beta_1 = 0$ quiere decir que nuestro modelo no ayuda a explicar a Y) H1: $\beta_1 \neq 0$ (El modelo sí es significativo para modelar a Y) Nosotros obtuvimos como resultado: Analysis of Variance Table Response: api00_cuad Df Sum Sq Mean Sq F value Pr(>F) meals 1 1.1577e+13 1.1577e+13 1923.8 < 2.2e-16 *** Residuals 398 2.3950e+12 6.0176e+09

— Signif. codes: 0 ‘’ **0.001** ‘’ 0.01 ‘’ 0.05 ‘’ 0.1 ‘’ 1

Lo que quiere decir que $p < 0.05$, es decir, rechazamos H0 por lo tanto el modelo si es significativo para modelar a $y = \text{academic performance of the school (api00)}$

v. Prueba de hipótesis con el modelo final

v. Con el modelo final ayude a un investigador a argumentar a favor o en contra de la hipótesis: “A mayor porcentaje de comidas gratis en la escuela es menor el desempeño de la escuela”.

v. Argumentar a favor o en contra de la hipótesis del investigador: “A mayor porcentaje de comidas gratis en la escuela es menor el desempeño...”

```
# Nuestro modelo 2 es: E(api00^2; meals) = beta_0 + beta_1 * meals
# Ahora vamos a plantear la matriz para que evaluemos únicamente a beta_1
MatZ0Z1 <- matrix(c(0, 1), ncol = 2, nrow = 1)
```

```
# Corremos la prueba formal unilateral usando alternative = "less" para poder evaluar si es menor
pruebaV <- glht(Ajuste2, linfct = MatZ0Z1, rhs = 0, alternative = "less")
summary(pruebaV)
```

Simultaneous Tests for General Linear Hypotheses

Fit: lm(formula = api00_cuad ~ meals, data = Datos)

Linear Hypotheses:

	Estimate	Std. Error	t value	Pr(<t)
1 >= 0	-5337.7	121.7	-43.86	<2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Adjusted p values reported -- single-step method)

Interpretación original de la prueba

Primero plantearemos una prueba de hipótesis unilateral sobre el coeficiente de nuestra variable $x = \text{'meals'}$ (β_1) y esta prueba tomara las siguientes hipótesis: $H_0: \beta_1 \geq 0$ (El porcentaje de comidas gratis NO disminuye el desempeño académico). $H_a: \beta_1 < 0$ (A mayor porcentaje de comidas gratis, el desempeño académico disminuye). Al ejecutar la prueba `glht`, nos da como resultado: -5337.7, coeficiente negativo y un p value de $< 2e-16$ así dado que $p < 0.05$, entonces rechazamos H_0

Así entonces con el investigador nosotros argumentaríamos a favor de la hipótesis del investigador, esto debido a la prueba de hipótesis unilateral anterior donde el resultado fue rechazar H_0 , es decir estamos a favor de la hipótesis. Por tanto concluimos que a mayor porcentaje de alumnos que reciben comidas gratis, el desempeño académico de la escuela disminuye